

目前进度：国际贸易上市公司一站式智能服务平台

截至 2026-08-29，版本 v0.2（待孵化）。本文档为进度与待办的唯一维护入口（合并原版本规划、优化方案、进度汇报三份文档）。

一、当前状态总览

六大功能模块全部可用：智能客服（RAG + SSE 流式）、知识库管理、多语言翻译（术语库 + 持久化翻译记忆）、智能文案（并发生成）、数据洞察、管理后台（JWT 鉴权）。

- 默认接入 **DeepSeek 真实模型**，无 Key 自动降级 Mock，全流程可跑通
- 测试：**冒烟 8 项 + 单元 14 项 + 租户隔离 3 项（共 25 项），全部通过；前端 `npm run build` 通过
- 安全：**注册防提权、CORS 白名单自适应、PBKDF2 + HS256 JWT（零第三方依赖）
- 性能：**BM25 索引缓存、向量矩阵缓存、文案多段并发、SSE 流式均已落地

二、已完成里程碑

阶段	内容
v0.1.0 脚手架 → v0.2 待孵化	六大模块 API、可插拔抽象层、混合检索、Vue 3 前端、Docker 编排;五轮迭代优化 (安全/性能/体验/数据/前端)
第一轮优化 (2026-08-28)	注册防提权 + grant-role; CORS 自适应; 文档按 doc_id 精确增删 + 同名替换; Token 用量接入真实 usage; BM25 索引缓存; 文案并发生成; SSE 流式 (前后端); 前端鉴权 (登录页 + 守卫 + 拦截器)
第二轮优化 (2026-08-29)	向量库矩阵缓存 + O(n) 删除; 翻译记忆 LRU + SQLite 持久化 (跨重启命中已实测); rerank 内部字段不泄漏; 12 项单元测试; launcher 跨平台
第三轮优化 (2026-08-29)	知识库重复数据清理重建 (同名重复全部消除); RAG 评测集 20 条 + 离线评估脚本 (scripts/eval_rag.py)，基线 Recall@3 = 100%、MRR = 0.90 (Mock Embedding + 4 chunk 小语料，语料扩充后需重测); 真实 rerank 接入 (RERANK_PROVIDER=cross_encoder，未装依赖自动回退 heuristic); 生产部署配置 (docker-compose.prod.yml + .env.production.example，多 worker / Chroma / 鉴权开启 / CORS 白名单); Alembic 迁移 (初始迁移含 8 张表，空库 upgrade/downgrade 验证通过，现有库已 stamp)

阶段	内容
第四轮 优化 (2026-08-29)	多租户隔离落地 : knowledge_docs / conversations 表加 tenant_id (Alembic 第二个迁移, 存量行自动回填), 知识库上传/列表/删除、客服问答 (含流式)、数据看板全链路按租户过滤, 检索器按租户过滤候选防止跨租户知识泄漏, 新增 tests/test_tenant.py 隔离测试; 评测集扩充至 52 条 (合同义改写/英文关键词), 并用评测集驱动 混合检索权重调优 : 0.6/0.4 → 0.4/0.6 (向量/BM25), Recall@3 96.2% → 100% , MRR 0.808 → 0.981 (Mock Embedding 下向量路噪声大, BM25 权重应更高; 接入真实 Embedding 后需重调)
第五轮 优化 (2026-08-29)	前端体验大改版 (已浏览器实测): 智能客服页新增欢迎区 + 8 张 快捷指令卡片 (点击即发送, 与知识库对齐) + 输入区上方快捷提问 chips, 流式问答全链路验证通过; 智能文案页重构为 一键文案 : 5 张文案模板卡片 (一键全套/商品详情/广告语/活动文案/SEO)、3 张示例商品卡片一键填充、分块独立复制 + 复制全部; 修复 axios 60s 超时小于全套文案生成时长 (90s+) 导致前端误报失败的 bug (超时放宽至 3 分钟); 全局页面背景统一; 版本升级 v0.2 (待孵化)
第六轮 优化 (2026-08-30)	LLM 故障转移 : LLM_FAILOVER 配置备用端点链 (base_url api_key model;...), 主端点连接失败/超时/429/5xx/401/403 时自动按序切换, 流式接口在首片段前同样生效 (已开始输出则不切换避免重复); 接入 小米 MiMo (api.xiaomimimo.com, mimo-v2.5-pro) 为主端点、DeepSeek v4-flash 为备用, 实测 MiMo 直连 200、客服问答与 SSE 流式 (21 个 delta) 均正常; 管理后台状态页展示备用端点模型列表; 单元测试增至 14 项

三、待办清单 (按优先级, 唯一维护入口)

L1 · 高优先级 (下一迭代, 1-2 周)

事项	说明
cross_encoder 实测	安装 sentence-transformers + 下载 bge-reranker (约 2GB), 对比启用前后的检索指标
真实 Embedding 接入与权重重调	配置 DashScope 等 Embedding Key 后重跑 scripts/eval_rag.py, 重调混合检索权重 (当前 0.4/0.6 为 Mock Embedding 实测最优)
ApiUsage 租户化	用量表加 tenant_id 列, Token 成本看板按租户统计

L2 · 中优先级 (1-2 个月)

- Redis: 会话状态、翻译记忆、索引共享 (多实例部署前提)
- 限流与 Token 配额 (防滥用与成本失控)
- LangGraph 图编排升级 (接口已预留)
- 监控告警 (Prometheus + Grafana); 流式覆盖翻译/文案
- 审计日志中间件统一埋点; 高频问答缓存
- 数据库生产化: SQLite → PostgreSQL (改 DATABASE_URL 即可)

L3 · 低优先级 / 长期

- 渠道扩展 (微信 / WhatsApp); MCP 工具化; 多模态商品图理解

- 查询改写 (Multi-Query)、情感分析、翻译质量评估、知识库版本管理
- 内容安全输出侧四层过滤；向量库 Milvus 生产化

四、已知风险

风险	对策
流式接口 Token 为估算值 (SSE 拿不到服务端 usage)	非流式路径已是真实值；后续用 stream_options 拿真实用量
SQLite 单机限制	多实例前迁移 PostgreSQL
LLM API 成本失控	高频缓存、限流、上下文裁剪 (L2 待办)
检索质量不达预期	评测集基线 + Rerank 模型 (L1 待办)

五、效果度量 KPI

指标	当前	目标
检索命中率	Recall@3 = 100% (评测集 52 条)	真实 Embedding + 扩充语料后保持 ≥ 85%
检索 MRR	0.981 (同上)	≥ 0.85
客服满意度	看板可见	≥ 4.0/5
人工转接率	待测	≤ 30%
问答响应 P95	待测	≤ 3s
知识条目数	示例 3 篇	≥ 10,000 条

六、推进原则

小步快跑 (每 2 周一迭代) · 数据驱动 (KPI 指导优化) · 可回滚 · 先跑通再跑好 (Mock → 真实逐层替换) · 安全底线前置。